AirSpline: modelado y validación de splines cúbicos para sensores virtuales de $PM_{2.5}$

Estudiantes:
Juan David Garrido (Ingeniero de Algoritmos y Simulación)
Edwin Quiñones (Ingeniero de Integración y Estrategia)
Miguel Angel Laiton (Ingeniero de Modelado y Validación)
Equipo AirSpline · Análisis Numérico para Ingeniería · Estudio de Caso 3 (*Air Health Analytics*)
Repositorio: https://github.com/JuanDGarridoR/Proyecto---Analisis-Numerico

***Resumen*—Se formula el problema de estimar la concentración de $PM_{2.5}$ cada 0.1 km a partir de 10 estaciones equidistantes en un corredor de 9 km, se justifica la condición de frontera del spline cúbico y se valida el modelo. La frontera *not-a-knot* se elige con evidencia: en la validación cruzada *leave-one-out* (LOOCV) sobre los 8 nodos internos obtiene RMSE = 1.045 $\mu g/m^3$ y error máximo 1.528 $\mu g/m^3$ (E7), un 72.4 % menos RMSE que la interpolación lineal y un 87.7 % menos que Lagrange. Se cuantifica el fenómeno de Runge en los nodos del corredor (constante de Lebesgue 17.85 para Lagrange frente a 1.97 para el spline) y se verifica el orden de convergencia $O(h^4)$ (observado 3.99). Finalmente, se analiza la robustez frente a ruido instrumental $\sigma = 2.5\,\mu g/m^3$: el ruido se amplifica $\times$2.48 en las estaciones de borde, pero los tramos de alerta son insensibles a la frontera elegida (desfase $\leq$ 5 m).**

***Palabras clave*—spline cúbico, fenómeno de Runge, constante de Lebesgue, validación cruzada, condiciones de frontera, $PM_{2.5}$.**

I. Introducción

AirSpline genera *sensores virtuales* de $PM_{2.5}$: a partir de 10 estaciones fijas (una por kilómetro) interpola la concentración en una malla de 91 puntos ($\Delta x = 0.1$ km) para emitir alertas sanitarias (amarilla $\geq 70\,\mu g/m^3$, roja $\geq 90\,\mu g/m^3$). Este informe documenta el trabajo del rol de Modelado y Validación, que corresponde a las secciones §2, §3 y §5 del cuaderno `AirSpline_Caso3.ipynb` y al módulo `modelado_validacion.py` del repositorio. Se distinguen dos preguntas: *verificación* (¿se resuelven bien las ecuaciones?) y *validación* (¿el modelo predice bien las estaciones que no ve?). Además de la LOOCV exigida, se analiza la robustez de la propia validación frente al ruido de los sensores.

II. Formulación del problema

II-A. Datos y modelo

Los nodos son $x_i = i\,\text{km}$, $i = 0, \ldots, 9$ ($n = 9$ tramos, $h = 1$ km), con lecturas

$$y = (45,\ 52,\ 68,\ 85,\ 92,\ 88,\ 79,\ 63,\ 48,\ 42)\ \mu g/m^3.$$

En cada tramo $[x_i, x_{i+1}]$ el spline es

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3. \quad (1)$$

Hay $4n = 36$ incógnitas: $2n = 18$ condiciones de interpolación, $2(n-1) = 16$ de continuidad de S' y S'' en los nodos internos (clase C^2) y 2 de frontera. Con $a_i = y_i$ y $c_i = S''(x_i)/2$ el problema se reduce a un sistema en las c_i [1]:

$$\begin{aligned} h_{i-1}c_{i-1} + 2(h_{i-1} + h_i)c_i + h_i c_{i+1} \\ = \tfrac{3}{h_i}(a_{i+1} - a_i) - \tfrac{3}{h_{i-1}}(a_i - a_{i-1}), \end{aligned} \quad (2)$$

para $i = 1, \ldots, n-1$, y luego $b_i = \frac{a_{i+1}-a_i}{h_i} - \frac{h_i}{3}(2c_i + c_{i+1})$, $d_i = \frac{c_{i+1}-c_i}{3h_i}$.

II-B. Sistema del caso

Con $h = 1$ la ecuación queda $c_{i-1} + 4c_i + c_{i+1} = 3(y_{i+1} - 2y_i + y_{i-1})$. Para la frontera natural ($c_0 = c_9 = 0$):

$$\begin{bmatrix} 4 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 4 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 4 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 4 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 4 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 4 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 4 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 4 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \\ c_5 \\ c_6 \\ c_7 \\ c_8 \end{bmatrix} = \begin{bmatrix} 27 \\ 3 \\ -30 \\ -33 \\ -15 \\ -21 \\ 3 \\ 27 \end{bmatrix} \quad (3)$$

La matriz es estrictamente diagonal dominante ($4 > 1+1$), luego no singular; sus valores propios $4 + 2\cos(k\pi/9) \in (2, 6)$ dan $\kappa_2 = 2.77$, y el algoritmo de Thomas la resuelve en $O(n)$ sin pivoteo. Para *not-a-knot* ($d_0 = d_1$, $d_7 = d_8$) se elimina $c_0 = 2c_1 - c_2$ (y su simétrico c_9): la primera y la última fila pasan a $6c_1 = r_1$ y $6c_8 = r_8$, con $\kappa_2 = 2.82$. Para mallas no uniformes (las que aparecen en la LOOCV) se usa la forma general de la eliminación, implementada en el módulo.

III. Selección de la condición de frontera

La Tabla I resume la evaluación. El criterio es doble: que la hipótesis tenga sentido físico y que el error de validación sea mínimo.

La elección *not-a-knot* coincide con la del cuaderno (`BC_PRINCIPAL`) y reduce el RMSE un 31.7 % frente a la natural. La diferencia entre ambas se concentra en los tramos de borde (máx $|\Delta S| = 0.79\,\mu g/m^3$ en km 0–1 y 8–9 frente a $0.21\,\mu g/m^3$ en el interior).

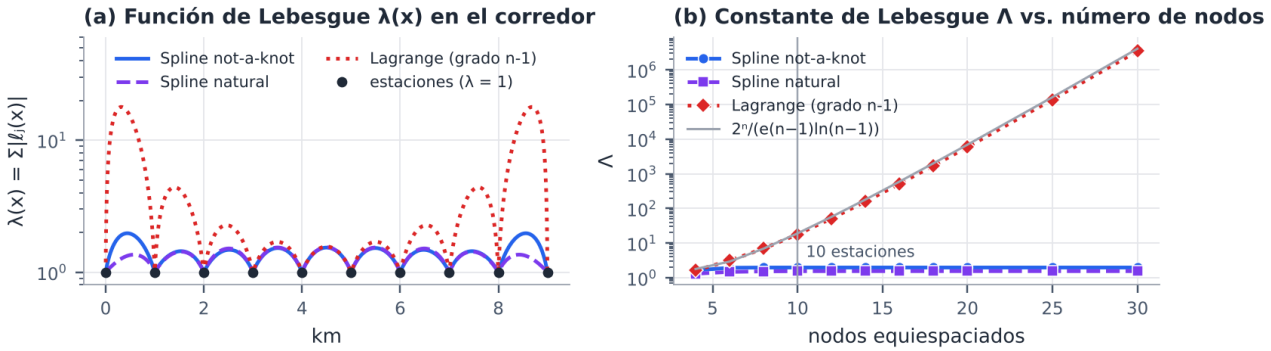


Figura 1. Fenómeno de Runge cuantificado. (a) Función de Lebesgue en los nodos del corredor: Lagrange amplifica hasta $\times 17.85$ cerca de los extremos; el spline se mantiene por debajo de 2. (b) Crecimiento exponencial de Λ para Lagrange (sigue la asintótica) y acotado para el spline.

Tabla I
Condiciones de frontera evaluadas (orden observado al refinar h y RMSE de la LOOCV, en μg/m^3)

Frontera	Condición	Hipótesis y comentario para el corredor	Orden	RMSE
Natural	$S''(0) = S''(9) = 0$	Supone curvatura nula en los extremos, pero los datos indican $S''_{\text{nak}}(0) = 15.7$ y $S''_{\text{nak}}(9) = 16.1$: hipótesis falsa, error $O(h^2)$ en los bordes.	2.00	1.529
Sujeta	$S'(0) = f'_0$, $S'(9) = f'_9$	Las pendientes no se miden; con `np.gradient` (unilateral, $O(h)$) el orden cae a 2.02 y la curvatura de borde cambia de signo ($S''(0) = -7.6$). Con f' exacta: 4.01.	2.02	1.852
Not-a-knot	S''' continua en x_1, x_8	Sin hipótesis física: la curvatura de borde la determinan los datos.	**3.99**	**1.045**
Periódica	S, S', S'' iguales en 0 y 9	Exige $y_0 = y_9$ y un dominio cerrado; el corredor es abierto y $45 \neq 42$. Descartada.	—	—
Lineal	—	Sólo C^0; recorta los picos.	2.00	3.787
Lagrange	grado 9	Inestable con nodos equidistantes (Sec. IV).	—	8.483

IV. Por qué el spline evita el fenómeno de Runge

IV-A. Error y estabilidad del polinomio de grado alto

El interpolante de Lagrange de grado 9 cumple $f(x) - P_9(x) = \frac{f^{(10)}(\xi)}{10!}\,\omega(x)$, con $\omega(x) = \prod_{i=0}^{9}(x - x_i)$. Con nodos equidistantes $|\omega|$ es 49 veces mayor en el tramo $[0, 1]$ que en $[4, 5]$: el error se concentra en los bordes del corredor [4], [5]. Además, si las lecturas tienen un error $|\delta_j| \le \delta$, el error inducido está acotado por $\Lambda\,\delta$, donde $\Lambda = \max_x \sum_j |\ell_j(x)|$ es la constante de Lebesgue y ℓ_j las funciones cardinales. Para nodos equidistantes $\Lambda_n \sim 2^{n+1}/(e\,n\ln n)$ [4]. Medida en los 10 nodos del corredor (Fig. 1a): $\Lambda = 17.85$ para Lagrange (cerca de km 0.32 y 0.32) frente a 1.97 (*not-a-knot*) y 1.54 (natural). Con 30 nodos, Lagrange llega a 3.4×10^6 mientras el spline sigue en 1.97 (Fig. 1b).

IV-B. Mecanismos del spline

1. *Grado fijo:* polinomios cúbicos por tramos; el grado no crece con el número de estaciones.
2. *Localidad:* la influencia de una estación decae $\approx 2 - \sqrt{3} \approx 0.268$ por tramo. Para E5 se mide 0.137, 0.037 y 0.012 a 1, 2 y 3 km, mientras que su función cardinal de Lagrange alcanza 4.03 en los tramos extremos: una perturbación en km 4 se amplifica en km 0–1.
3. *Mínima curvatura:* entre las funciones C^2 que interpolan los datos, el spline natural minimiza $\int (f'')^2 dx$ [2], [6]; no puede "inventar" oscilaciones. Lagrange presenta 4 extremos locales (los datos tienen 1) y un exceso de variación total de 4.28 μg/m^3; el *not-a-knot*, 0.08 μg/m^3 (un mínimo de 41.98 junto a km 9, despreciable).
4. *Convergencia:* con pendientes exactas $\|f - S\|_\infty \le \frac{5}{384} h^4 \|f^{(4)}\|_\infty$ [3]. Sobre una pluma gaussiana de referencia el orden observado es 3.99 (*not-a-knot*) y 4.01 (sujeta exacta), frente a 2.00 (natural) y 2.00 (lineal), Fig. 2a. Para $1/(1 + 25x^2)$ el error de Lagrange crece de 0.44 a 59.8 entre 5 y 21 nodos, y el del spline baja a 0.0032 (Fig. 2b).

V. Verificación de la implementación

Se programó el spline con las tres fronteras (sistema de la Sec. II y algoritmo de Thomas) y se comparó con `scipy.interpolate.CubicSpline` [8] en la malla uniforme y en las 8 mallas no uniformes de la LOOCV: la diferencia máxima de coeficientes es 1.4×10^{-14} y todos los sistemas resultaron estrictamente diagonal dominantes. Los saltos de S, S' y S'' en los nodos internos son $\le 1.4 \times 10^{-14}$ (clase C^2) y, en el *not-a-knot*, el salto de S''' en x_1 y x_8 es nulo, como exige la condición. Estas

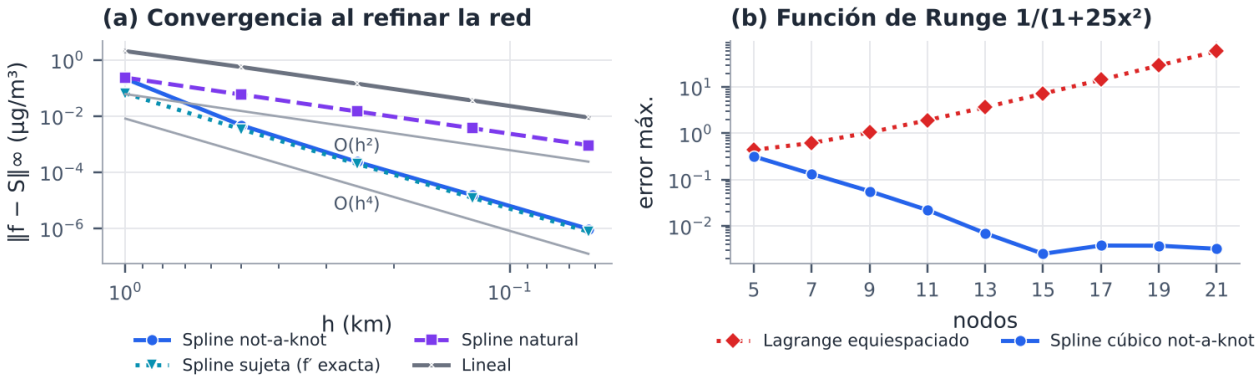


Figura 2. Verificación del orden de convergencia. (a) $\|f - S\|_\infty$ vs. h: *not-a-knot* y sujeta con f' exacta siguen $O(h^4)$; la natural y la lineal, $O(h^2)$. (b) Función de Runge: Lagrange diverge y el spline converge.

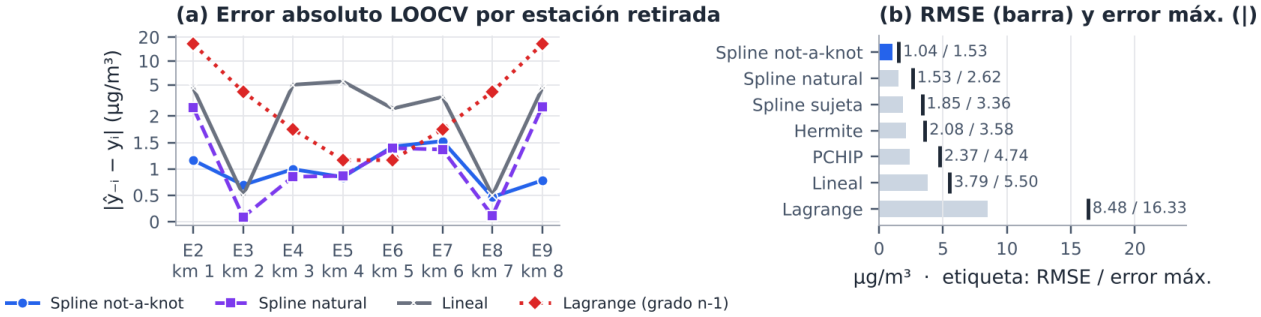


Figura 3. Validación LOOCV en los 8 nodos internos. (a) Error absoluto por estación retirada (eje simétrico-logarítmico). (b) RMSE (barra; resaltado el modelo elegido) y error máximo (marca) por método.

comprobaciones forman parte de 26 pruebas automáticas (`pytest`).

VI. Validación cruzada leave-one-out

VI-A. *Esquema*

Para cada estación interna E_{i+1}, $i = 1, \ldots, 8$, se retira el dato, se ajusta el modelo con las 9 restantes (malla no uniforme con un hueco de 2 km) y se predice el valor retirado:

$$e_i = \hat{y}_{-i}(x_i) - y_i, \quad \text{RMSE} = \sqrt{\tfrac{1}{8}\textstyle\sum e_i^2}, \quad e_{\max} = \max_i |e_i|. \tag{4}$$

E1 y E10 no se retiran porque su predicción sería una extrapolación. La LOOCV simula exactamente la falla de una estación [7] y, al predecir a través de un hueco de $2h$, es una estimación conservadora del error del modelo final con $h = 1$ km.

```
def loocv(x, y, nombres):
    filas = []
    for i in range(1, len(x) - 1):      # nodos internos
        m = np.ones(len(x), bool)
        m[i] = False                    # retirar la estación
        mods = construir_modelos(x[m], y[m])   # 9 datos
        filas.append({n: float(mods[n](x[i])) - y[i]
                      for n in nombres})  # e_i con signo
    e = pd.DataFrame(filas)
    return np.sqrt((e**2).mean()), e.abs().max()   # RMSE, e_max
```

Tabla II
LOOCV: error con signo e_i por estación retirada y métricas (μg/m^3). En negrita, el mejor.

Est.	y_i	NaK	Nat.	Suj.	Herm.	PCHIP	Lin.	Lagr.
E2	52	−1.16	+2.55	+3.32	+3.58	+2.95	+4.50	+16.33
E3	68	+0.70	+0.09	−0.14	+0.50	+0.50	+0.50	−4.08
E4	85	−1.00	−0.85	−0.79	−1.67	−1.52	−5.00	+1.75
E5	92	−0.84	−0.87	−0.88	−1.17	−4.74	−5.50	−1.17
E6	88	+1.42	+1.39	+1.38	+1.33	−0.08	−2.50	+1.17
E7	79	−1.53	−1.37	−1.30	−1.67	−1.49	−3.50	−1.75
E8	63	+0.47	−0.11	−0.33	+0.00	−0.20	+0.50	+4.08
E9	48	−0.78	+2.62	+3.36	+3.58	+2.96	+4.50	−16.33
RMSE		**1.04**	1.53	1.85	2.08	2.37	3.79	8.48
MAE		**0.99**	1.23	1.44	1.69	1.81	3.31	5.83
$e_{\max}$		**1.53**	2.62	3.36	3.58	4.74	5.50	16.33
Peor		E7	E9	E9	E2	E5	E5	E2

VI-B. *Resultados*

La Tabla II y la Fig. 3 muestran que el spline *not-a-knot* es el mejor en las tres métricas: RMSE = 1.045, MAE = 0.987 y $e_{\max} = 1.528\,\mu$g/m^3 (E7, flanco de descenso). Las fronteras natural y sujeta fallan en E2 y E9, justo donde actúa su hipótesis de borde. Lagrange (grado 8 sobre nodos no equidistantes) comete errores de $\pm 16.333\,\mu$g/m^3 en E2/E9, y la lineal subestima el pico de E5 en $5.5\,\mu$g/m^3: su alerta roja queda en km 3.71–4.50

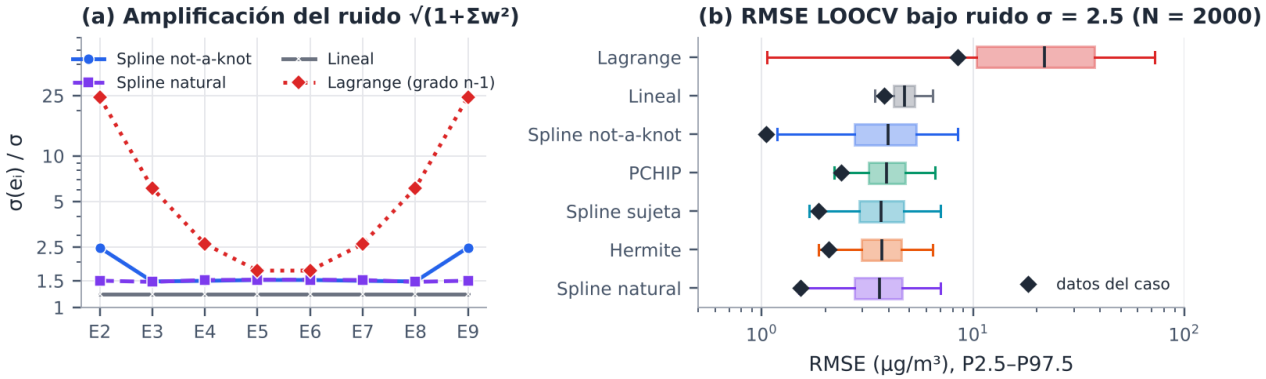


Figura 4. Robustez. (a) Factor de amplificación del ruido en el error LOOCV de cada estación. (b) Distribución del RMSE LOOCV bajo ruido (caja: P25–P75; bigotes: P2.5–P97.5) y RMSE con los datos del caso (rombo).

frente a 3.49–4.68 del spline (226 m de diferencia).

VII. Robustez de la validación ante el ruido

VII-A. Amplificación analítica

Para los métodos lineales en los datos (todos salvo PCHIP) el vector de errores LOOCV es $e = My$, con M de 8×10. Si cada lectura tiene ruido independiente $N(0, \sigma^2)$, la desviación de e_i es $\sigma\|M_i\|_2 = \sigma\sqrt{1 + \sum_j w_{ij}^2}$. Para la lineal es $\sqrt{1.5} = 1.225$ en todas las estaciones; para el *not-a-knot* es ≈ 1.5 en el interior pero 2.48 en E2/E9; la natural, 1.50; Lagrange, 24.5 (Fig. 4a).

VII-B. LOOCV bajo ruido $\sigma = 2.5\,\mu g/m^3$

Se repitió la LOOCV en 2000 realizaciones $y+\varepsilon$ (semilla 2024; Fig. 4b). Con ruido fuerte, los métodos cúbicos C^1/C^2 quedan estadísticamente empatados (medias de 3.78 a 4.17 μg/m^3 con intervalos muy superpuestos) y ninguno domina: el *not-a-knot* obtiene el menor RMSE en el 31 % de las realizaciones, pero su mayor sensibilidad en los bordes eleva su media. Lineal (4.78) y Lagrange (26.0) siguen siendo peores. Esto concuerda con la banda Monte Carlo de la §8 del cuaderno (replicada de forma independiente): su ancho máximo, 11.23 μg/m^3, ocurre en km 8.4, y el mínimo, 6.93, en km 4.4.

VII-C. Interpretación

El RMSE observado del *not-a-knot* (1.045) cae en el percentil 1.7 de su distribución bajo ruido: si cada lectura tuviera ruido independiente de 2.5 μg/m^3 sería muy improbable un error tan bajo. Atribuyendo toda la discrepancia LOOCV a ruido, éste sería a lo sumo $\approx$0.58 μg/m^3; las lecturas del caso se comportan como promedios. Por tanto, $\sigma = 2.5$ es un escenario *conservador*, adecuado para alertas sanitarias. Por último, los tramos de alerta (amarilla km 2.11–6.59; roja km 3.49–4.68) cambian a lo sumo 5 m entre las fronteras *not-a-knot*, natural y sujeta, y 45 m con Hermite o PCHIP: con una malla de 100 m, la elección de frontera no altera ninguna alerta.

VIII. Conclusiones y entregables al equipo

- **Modelo:** spline cúbico *not-a-knot* (`CubicSpline`, `bc_type="not-a-knot"`), clase C^2, orden $O(h^4)$, seleccionado por LOOCV y sin hipótesis artificiales de borde.
- **KPIs para Integración y Estrategia:** RMSE = 1.045 μg/m^3, $e_{\text{máx}} = 1.528\,\mu$g/m^3, -72.4 % de RMSE frente a la lineal y -87.7 % frente a Lagrange.
- **Para Algoritmos y Simulación:** la incertidumbre es mayor en km 0–1 y 8–9 (factor 2.48); la banda Monte Carlo debe acompañar siempre a la alerta.
- **Hallazgo de validación:** la búsqueda de tramos de alerta para lineal y Lagrange perdía las raíces que caen sobre la malla (km 4.5 con umbral 90); quedó corregida y con prueba de regresión.
- **Limitaciones y trabajo futuro:** modelo 1-D con 10 datos y 8 pliegues (métricas de alta varianza); no modela viento ni tráfico. Si el ruido real fuera del orden de $\sigma = 2.5$, convendría un spline de *suavizado* con parámetro elegido por validación cruzada generalizada, o kriging.

Referencias

[1] R. L. Burden, J. D. Faires y A. M. Burden, *Análisis numérico*, 10.ª ed. México: Cengage Learning, 2017, cap. 3.

[2] C. de Boor, *A Practical Guide to Splines*, ed. rev. New York, NY, USA: Springer, 2001.

[3] C. A. Hall y W. W. Meyer, "Optimal error bounds for cubic spline interpolation," *J. Approx. Theory*, vol. 16, no. 2, pp. 105–122, 1976.

[4] L. N. Trefethen, *Approximation Theory and Approximation Practice*, ed. ampliada. Philadelphia, PA, USA: SIAM, 2019.

[5] C. Runge, "Über empirische Funktionen und die Interpolation zwischen äquidistanten Ordinaten," *Z. Math. Phys.*, vol. 46, pp. 224–243, 1901.

[6] J. C. Holladay, "A smoothest curve approximation," *Math. Tables Aids Comput.*, vol. 11, no. 60, pp. 233–243, 1957.

[7] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. New York, NY, USA: Springer, 2009, cap. 7.

[8] P. Virtanen *et al.*, "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nat. Methods*, vol. 17, pp. 261–272, 2020.