# AirSpline: modelado y validación de splines cúbicos para sensores virtuales de $PM_{2.5}$

Miguel Angel Laiton
*Ingeniero de Modelado y Validación* — Equipo AirSpline
Análisis Numérico para Ingeniería · Estudio de Caso 3 (*Air Health Analytics*)
Equipo: Juan David Garrido (Algoritmos y Simulación) · Edwin Quiñones (Integración y Estrategia)
Repositorio: https://github.com/JuanDGarridoR/Proyecto---Analisis-Numerico

***Resumen*—Se formula el problema de estimar la concentración de $PM_{2.5}$ cada 0.1 km a partir de 10 estaciones equidistantes en un corredor de 9 km, se justifica la condición de frontera del spline cúbico y se valida el modelo. La frontera *not-a-knot* se elige con evidencia: en la validación cruzada *leave-one-out* (LOOCV) sobre los 8 nodos internos obtiene RMSE = 1.045 $\mu$g/m³ y error máximo 1.528 $\mu$g/m³ (E7), un 72.4 % menos RMSE que la interpolación lineal y un 87.7 % menos que Lagrange. Se cuantifica el fenómeno de Runge en los nodos del corredor (constante de Lebesgue 17.85 para Lagrange frente a 1.97 para el spline) y se verifica el orden de convergencia $O(h^4)$ (observado 3.99). Finalmente, se analiza la robustez frente a ruido instrumental $\sigma = 2.5\,\mu$g/m³: el ruido se amplifica ×2.48 en las estaciones de borde, pero los tramos de alerta son insensibles a la frontera elegida (desfase ≤ 5 m).**

***Palabras clave*—spline cúbico, fenómeno de Runge, constante de Lebesgue, validación cruzada, condiciones de frontera, $PM_{2.5}$.**

## I. Introducción

AirSpline genera *sensores virtuales* de $PM_{2.5}$: a partir de 10 estaciones fijas (una por kilómetro) interpola la concentración en una malla de 91 puntos ($\Delta x = 0.1$ km) para emitir alertas sanitarias (amarilla $\geq 70\,\mu$g/m³, roja $\geq 90\,\mu$g/m³). Este informe documenta el trabajo del rol de Modelado y Validación, que corresponde a las secciones §2, §3 y §5 del cuaderno `AirSpline_Caso3.ipynb` y al módulo `modelado_validacion.py` del repositorio. Se distinguen dos preguntas: *verificación* (¿se resuelven bien las ecuaciones?) y *validación* (¿el modelo predice bien las estaciones que no ve?). Además de la LOOCV exigida, se analiza la robustez de la propia validación frente al ruido de los sensores.

## II. Formulación del problema

### II-A. Datos y modelo

Los nodos son $x_i = i\,$km, $i = 0, \ldots, 9$ ($n = 9$ tramos, $h = 1$ km), con lecturas

$$y = (45,\ 52,\ 68,\ 85,\ 92,\ 88,\ 79,\ 63,\ 48,\ 42)\ \mu\text{g/m}^3.$$

En cada tramo $[x_i, x_{i+1}]$ el spline es

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3. \quad (1)$$

Hay $4n = 36$ incógnitas: $2n = 18$ condiciones de interpolación, $2(n-1) = 16$ de continuidad de $S'$ y $S''$ en los nodos internos (clase $C^2$) y 2 de frontera. Con $a_i = y_i$ y $c_i = S''(x_i)/2$ el problema se reduce a un sistema en las $c_i$ [1]:

$$\begin{aligned} h_{i-1}c_{i-1} + 2(h_{i-1} + h_i)c_i + h_i c_{i+1} \\ = \tfrac{3}{h_i}(a_{i+1} - a_i) - \tfrac{3}{h_{i-1}}(a_i - a_{i-1}), \end{aligned} \quad (2)$$

para $i = 1, \ldots, n-1$, y luego $b_i = \frac{a_{i+1}-a_i}{h_i} - \frac{h_i}{3}(2c_i + c_{i+1})$, $d_i = \frac{c_{i+1}-c_i}{3h_i}$.

### II-B. Sistema del caso

Con $h = 1$ la ecuación queda $c_{i-1} + 4c_i + c_{i+1} = 3(y_{i+1} - 2y_i + y_{i-1})$. Para la frontera natural ($c_0 = c_9 = 0$):

$$\begin{bmatrix} 4 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 4 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 4 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 4 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 4 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 4 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 4 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 4 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \\ c_5 \\ c_6 \\ c_7 \\ c_8 \end{bmatrix} = \begin{bmatrix} 27 \\ 3 \\ -30 \\ -33 \\ -15 \\ -21 \\ 3 \\ 27 \end{bmatrix} \quad (3)$$

La matriz es estrictamente diagonal dominante ($4 > 1+1$), luego no singular; sus valores propios $4 + 2\cos(k\pi/9) \in (2, 6)$ dan $\kappa_2 = 2.77$, y el algoritmo de Thomas la resuelve en $O(n)$ sin pivoteo. Para *not-a-knot* ($d_0 = d_1$, $d_7 = d_8$) se elimina $c_0 = 2c_1 - c_2$ (y su simétrico $c_9$): la primera y la última fila pasan a $6c_1 = r_1$ y $6c_8 = r_8$, con $\kappa_2 = 2.82$. Para mallas no uniformes (las que aparecen en la LOOCV) se usa la forma general de la eliminación, implementada en el módulo.

## III. Selección de la condición de frontera

La Tabla I resume la evaluación. El criterio es doble: que la hipótesis tenga sentido físico y que el error de validación sea mínimo.

La elección *not-a-knot* coincide con la del cuaderno (`BC_PRINCIPAL`) y reduce el RMSE un 31.7 % frente a la natural. La diferencia entre ambas se concentra en los tramos de borde (máx $|\Delta S| = 0.79\,\mu$g/m³ en km 0–1 y 8–9 frente a $0.21\,\mu$g/m³ en el interior).

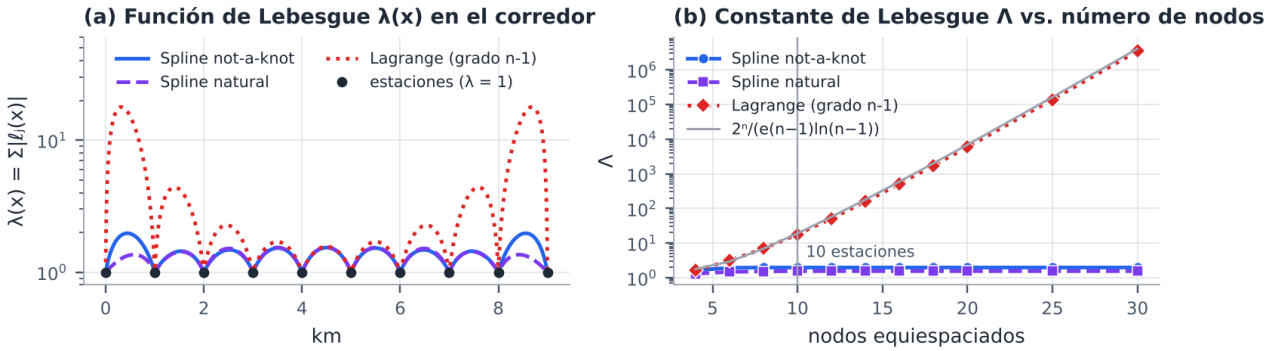



Figura 1. Fenómeno de Runge cuantificado. (a) Función de Lebesgue en los nodos del corredor: Lagrange amplifica hasta $\times 17.85$ cerca de los extremos; el spline se mantiene por debajo de 2. (b) Crecimiento exponencial de $\Lambda$ para Lagrange (sigue la asintótica) y acotado para el spline.

Tabla I
Condiciones de frontera evaluadas (orden observado al refinar $h$ y RMSE de la LOOCV, en $\mu$g/m$^3$)

| Frontera | Condición | Hipótesis y comentario para el corredor | Orden | RMSE |
|---|---|---|---|---|
| Natural | $S''(0) = S''(9) = 0$ | Supone curvatura nula en los extremos, pero los datos indican $S''_{\text{nak}}(0) = 15.7$ y $S''_{\text{nak}}(9) = 16.1$: hipótesis falsa, error $O(h^2)$ en los bordes. | 2.00 | 1.529 |
| Sujeta | $S'(0) = f'_0$, $S'(9) = f'_9$ | Las pendientes no se miden; con `np.gradient` (unilateral, $O(h)$) el orden cae a 2.02 y la curvatura de borde cambia de signo ($S''(0) = -7.6$). Con $f'$ exacta: 4.01. | 2.02 | 1.852 |
| **Not-a-knot** | $S'''$ continua en $x_1$, $x_8$ | Sin hipótesis física: la curvatura de borde la determinan los datos. | **3.99** | **1.045** |
| Periódica | $S, S', S''$ iguales en 0 y 9 | Exige $y_0 = y_9$ y un dominio cerrado; el corredor es abierto y $45 \neq 42$. Descartada. | — | — |
| Lineal | — | Sólo $C^0$; recorta los picos. | 2.00 | 3.787 |
| Lagrange | grado 9 | Inestable con nodos equidistantes (Sec. IV). | — | 8.483 |

## IV. Por qué el spline evita el fenómeno de Runge

### IV-A. Error y estabilidad del polinomio de grado alto

El interpolante de Lagrange de grado 9 cumple $f(x) - P_9(x) = \frac{f^{(10)}(\xi)}{10!}\,\omega(x)$, con $\omega(x) = \prod_{i=0}^{9}(x - x_i)$. Con nodos equidistantes $|\omega|$ es 49 veces mayor en el tramo $[0, 1]$ que en $[4, 5]$: el error se concentra en los bordes del corredor [4], [5]. Además, si las lecturas tienen un error $|\delta_j| \le \delta$, el error inducido está acotado por $\Lambda\,\delta$, donde $\Lambda = \max_x \sum_j |\ell_j(x)|$ es la constante de Lebesgue y $\ell_j$ las funciones cardinales. Para nodos equidistantes $\Lambda_n \sim 2^{n+1}/(e\,n\ln n)$ [4]. Medida en los 10 nodos del corredor (Fig. 1a): $\Lambda = 17.85$ para Lagrange (cerca de km 0.32 y 0.32) frente a 1.97 (*not-a-knot*) y 1.54 (natural). Con 30 nodos, Lagrange llega a $3.4 \times 10^6$ mientras el spline sigue en 1.97 (Fig. 1b).

### IV-B. Mecanismos del spline

1. *Grado fijo:* polinomios cúbicos por tramos; el grado no crece con el número de estaciones.
2. *Localidad:* la influencia de una estación decae $\approx 2 - \sqrt{3} \approx 0.268$ por tramo. Para E5 se mide 0.137, 0.037 y 0.012 a 1, 2 y 3 km, mientras que su función cardinal de Lagrange alcanza 4.03 en los tramos extremos: una perturbación en km 4 se amplifica en km 0–1.
3. *Mínima curvatura:* entre las funciones $C^2$ que interpolan los datos, el spline natural minimiza $\int (f'')^2 dx$ [2], [6]; no puede "inventar" oscilaciones. Lagrange presenta 4 extremos locales (los datos tienen 1) y un exceso de variación total de 4.28 $\mu$g/m$^3$; el *not-a-knot*, 0.08 $\mu$g/m$^3$ (un mínimo de 41.98 junto a km 9, despreciable).
4. *Convergencia:* con pendientes exactas $\|f - S\|_\infty \le \frac{5}{384} h^4 \|f^{(4)}\|_\infty$ [3]. Sobre una pluma gaussiana de referencia el orden observado es 3.99 (*not-a-knot*) y 4.01 (sujeta exacta), frente a 2.00 (natural) y 2.00 (lineal), Fig. 2a. Para $1/(1 + 25x^2)$ el error de Lagrange crece de 0.44 a 59.8 entre 5 y 21 nodos, y el del spline baja a 0.0032 (Fig. 2b).

## V. Verificación de la implementación

Se programó el spline con las tres fronteras (sistema de la Sec. II y algoritmo de Thomas) y se comparó con `scipy.interpolate.CubicSpline` [8] en la malla uniforme y en las 8 mallas no uniformes de la LOOCV: la diferencia máxima de coeficientes es $1.4 \times 10^{-14}$ y todos los sistemas resultaron estrictamente diagonal dominantes. Los saltos de $S$, $S'$ y $S''$ en los nodos internos son $\le 1.4 \times 10^{-14}$ (clase $C^2$) y, en el *not-a-knot*, el salto de $S'''$ en $x_1$ y $x_8$ es nulo, como exige la condición. Estas

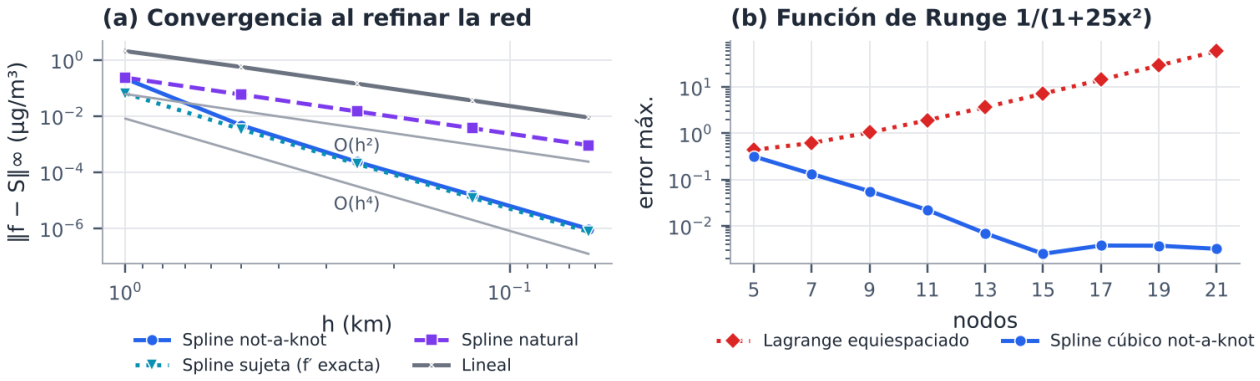



Figura 2. Verificación del orden de convergencia. (a) $\|f - S\|_\infty$ vs. $h$: *not-a-knot* y sujeta con $f'$ exacta siguen $O(h^4)$; la natural y la lineal, $O(h^2)$. (b) Función de Runge: Lagrange diverge y el spline converge.

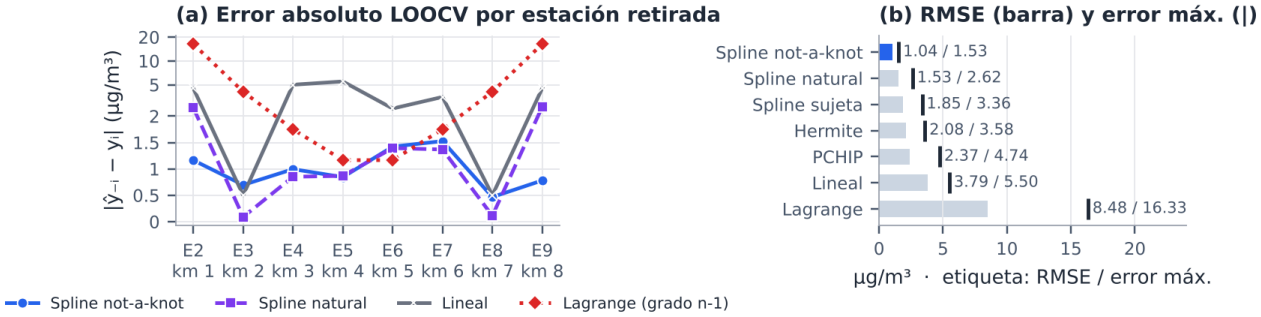



Figura 3. Validación LOOCV en los 8 nodos internos. (a) Error absoluto por estación retirada (eje simétrico-logarítmico). (b) RMSE (barra; resaltado el modelo elegido) y error máximo (marca) por método.

comprobaciones forman parte de 26 pruebas automáticas (`pytest`).

## VI. Validación cruzada leave-one-out

### VI-A. *Esquema*

Para cada estación interna $E_{i+1}$, $i = 1, \ldots, 8$, se retira el dato, se ajusta el modelo con las 9 restantes (malla no uniforme con un hueco de 2 km) y se predice el valor retirado:

$$e_i = \hat{y}_{-i}(x_i) - y_i, \quad \mathrm{RMSE} = \sqrt{\tfrac{1}{8}\textstyle\sum e_i^2}, \quad e_{\max} = \max_i |e_i|. \tag{4}$$

E1 y E10 no se retiran porque su predicción sería una extrapolación. La LOOCV simula exactamente la falla de una estación [7] y, al predecir a través de un hueco de $2h$, es una estimación conservadora del error del modelo final con $h = 1$ km.

```
def loocv(x, y, nombres):
    filas = []
    for i in range(1, len(x) - 1):      # nodos internos
        m = np.ones(len(x), bool)
        m[i] = False                    # retirar la estación
        mods = construir_modelos(x[m], y[m])   # 9 datos
        filas.append({n: float(mods[n](x[i])) - y[i]
                      for n in nombres})  # e_i con signo
    e = pd.DataFrame(filas)
    return np.sqrt((e**2).mean()), e.abs().max()   # RMSE, e_max
```

Tabla II
LOOCV: error con signo $e_i$ por estación retirada y métricas ($\mu$g/m$^3$). En negrita, el mejor.

| Est. | $y_i$ | NaK | Nat. | Suj. | Herm. | PCHIP | Lin. | Lagr. |
|---|---|---|---|---|---|---|---|---|
| E2 | 52 | −1.16 | +2.55 | +3.32 | +3.58 | +2.95 | +4.50 | +16.33 |
| E3 | 68 | +0.70 | +0.09 | −0.14 | +0.50 | +0.50 | +0.50 | −4.08 |
| E4 | 85 | −1.00 | −0.85 | −0.79 | −1.67 | −1.52 | −5.00 | +1.75 |
| E5 | 92 | −0.84 | −0.87 | −0.88 | −1.17 | −4.74 | −5.50 | −1.17 |
| E6 | 88 | +1.42 | +1.39 | +1.38 | +1.33 | −0.08 | −2.50 | +1.17 |
| E7 | 79 | −1.53 | −1.37 | −1.30 | −1.67 | −1.49 | −3.50 | −1.75 |
| E8 | 63 | +0.47 | −0.11 | −0.33 | +0.00 | −0.20 | +0.50 | +4.08 |
| E9 | 48 | −0.78 | +2.62 | +3.36 | +3.58 | +2.96 | +4.50 | −16.33 |
| RMSE | | **1.04** | 1.53 | 1.85 | 2.08 | 2.37 | 3.79 | 8.48 |
| MAE | | **0.99** | 1.23 | 1.44 | 1.69 | 1.81 | 3.31 | 5.83 |
| $e_{\max}$ | | **1.53** | 2.62 | 3.36 | 3.58 | 4.74 | 5.50 | 16.33 |
| Peor | | E7 | E9 | E9 | E2 | E5 | E5 | E2 |

### VI-B. *Resultados*

La Tabla II y la Fig. 3 muestran que el spline *not-a-knot* es el mejor en las tres métricas: RMSE = 1.045, MAE = 0.987 y $e_{\max} = 1.528\,\mu$g/m$^3$ (E7, flanco de descenso). Las fronteras natural y sujeta fallan en E2 y E9, justo donde actúa su hipótesis de borde. Lagrange (grado 8 sobre nodos no equidistantes) comete errores de $\pm 16.333\,\mu$g/m$^3$ en E2/E9, y la lineal subestima el pico de E5 en $5.5\,\mu$g/m$^3$: su alerta roja queda en km 3.71–4.50

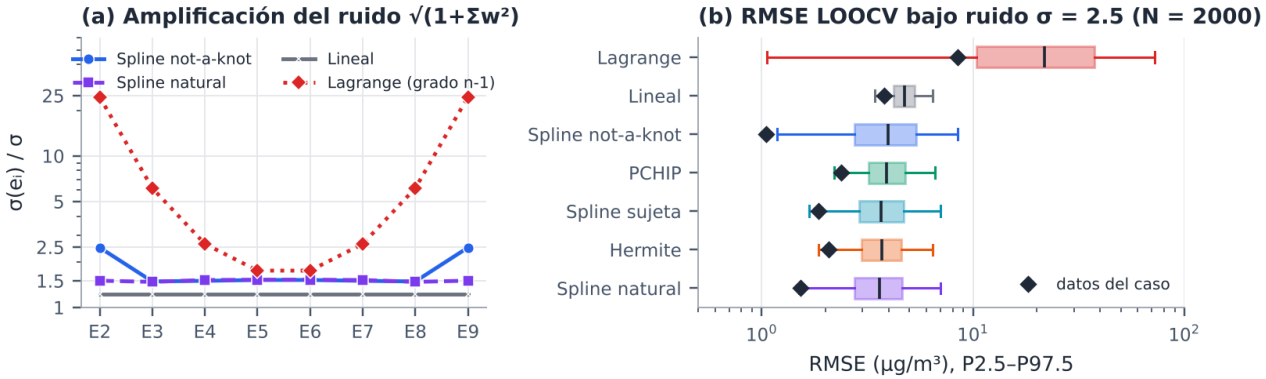



Figura 4. Robustez. (a) Factor de amplificación del ruido en el error LOOCV de cada estación. (b) Distribución del RMSE LOOCV bajo ruido (caja: P25–P75; bigotes: P2.5–P97.5) y RMSE con los datos del caso (rombo).

frente a 3.49–4.68 del spline (226 m de diferencia).

## VII. Robustez de la validación ante el ruido

### *VII-A. Amplificación analítica*

Para los métodos lineales en los datos (todos salvo PCHIP) el vector de errores LOOCV es $e = My$, con $M$ de $8 \times 10$. Si cada lectura tiene ruido independiente $N(0, \sigma^2)$, la desviación de $e_i$ es $\sigma\|M_i\|_2 = \sigma\sqrt{1 + \sum_j w_{ij}^2}$. Para la lineal es $\sqrt{1.5} = 1.225$ en todas las estaciones; para el *not-a-knot* es $\approx 1.5$ en el interior pero 2.48 en E2/E9; la natural, 1.50; Lagrange, 24.5 (Fig. 4a).

### *VII-B. LOOCV bajo ruido $\sigma = 2.5\,\mu g/m^3$*

Se repitió la LOOCV en 2000 realizaciones $y+\varepsilon$ (semilla 2024; Fig. 4b). Con ruido fuerte, los métodos cúbicos $C^1/C^2$ quedan estadísticamente empatados (medias de 3.78 a 4.17 $\mu$g/m$^3$ con intervalos muy superpuestos) y ninguno domina: el *not-a-knot* obtiene el menor RMSE en el 31 % de las realizaciones, pero su mayor sensibilidad en los bordes eleva su media. Lineal (4.78) y Lagrange (26.0) siguen siendo peores. Esto concuerda con la banda Monte Carlo de la §8 del cuaderno (replicada de forma independiente): su ancho máximo, 11.23 $\mu$g/m$^3$, ocurre en km 8.4, y el mínimo, 6.93, en km 4.4.

### *VII-C. Interpretación*

El RMSE observado del *not-a-knot* (1.045) cae en el percentil 1.7 de su distribución bajo ruido: si cada lectura tuviera ruido independiente de 2.5 $\mu$g/m$^3$ sería muy improbable un error tan bajo. Atribuyendo toda la discrepancia LOOCV a ruido, éste sería a lo sumo $\approx$0.58 $\mu$g/m$^3$; las lecturas del caso se comportan como promedios. Por tanto, $\sigma = 2.5$ es un escenario *conservador*, adecuado para alertas sanitarias. Por último, los tramos de alerta (amarilla km 2.11–6.59; roja km 3.49–4.68) cambian a lo sumo 5 m entre las fronteras *not-a-knot*, natural y sujeta, y 45 m con Hermite o PCHIP: con una malla de 100 m, la elección de frontera no altera ninguna alerta.

## VIII. Conclusiones y entregables al equipo

- **Modelo:** spline cúbico *not-a-knot* (`CubicSpline`, `bc_type="not-a-knot"`), clase $C^2$, orden $O(h^4)$, seleccionado por LOOCV y sin hipótesis artificiales de borde.
- **KPIs para Integración y Estrategia:** RMSE = 1.045 $\mu$g/m$^3$, $e_{\text{máx}} = 1.528\,\mu$g/m$^3$, $-72.4$ % de RMSE frente a la lineal y $-87.7$ % frente a Lagrange.
- **Para Algoritmos y Simulación:** la incertidumbre es mayor en km 0–1 y 8–9 (factor 2.48); la banda Monte Carlo debe acompañar siempre a la alerta.
- **Hallazgo de validación:** la búsqueda de tramos de alerta para lineal y Lagrange perdía las raíces que caen sobre la malla (km 4.5 con umbral 90); quedó corregida y con prueba de regresión.
- **Limitaciones y trabajo futuro:** modelo 1-D con 10 datos y 8 pliegues (métricas de alta varianza); no modela viento ni tráfico. Si el ruido real fuera del orden de $\sigma = 2.5$, convendría un spline de *suavizado* con parámetro elegido por validación cruzada generalizada, o kriging.

## Referencias


[1] R. L. Burden, J. D. Faires y A. M. Burden, *Análisis numérico*, 10.ª ed. México: Cengage Learning, 2017, cap. 3.

[2] C. de Boor, *A Practical Guide to Splines*, ed. rev. New York, NY, USA: Springer, 2001.

[3] C. A. Hall y W. W. Meyer, "Optimal error bounds for cubic spline interpolation," *J. Approx. Theory*, vol. 16, no. 2, pp. 105–122, 1976.

[4] L. N. Trefethen, *Approximation Theory and Approximation Practice*, ed. ampliada. Philadelphia, PA, USA: SIAM, 2019.

[5] C. Runge, "Über empirische Funktionen und die Interpolation zwischen äquidistanten Ordinaten," *Z. Math. Phys.*, vol. 46, pp. 224–243, 1901.

[6] J. C. Holladay, "A smoothest curve approximation," *Math. Tables Aids Comput.*, vol. 11, no. 60, pp. 233–243, 1957.

[7] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. New York, NY, USA: Springer, 2009, cap. 7.

[8] P. Virtanen *et al.*, "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nat. Methods*, vol. 17, pp. 261–272, 2020.